

시계열 분석 강의

1. 시계열의 구성과 확률보행

학습목표

- ▶ 시계열 소개
- ▶ 시계열의 세 가지 주요 구성요소 이해
- ▶ 베이스라인 모델 구축 및 평가지표 이해
- ▶ 확률보행 프로세스 식별, 자기상관함수 이해
- ▶ 차분, 정상성, 백색소음 분류
- ▶ AutoCorrelation Function 도식화
- ▶ 확률보행 예측

1. 시계열의 구성요소 이해


◆ 시계열

- ✓ 시간에 따라 정렬된 데이터 요소의 집합
 - 동일한 시간 단계로 분포하는데, 이는 매시간, 매분, 매월, 매분기 등의 주기로 기록됨
 - 주식의 종가, 가정의 전기 소비량, 실외 온도

1. 시계열의 구성요소 이해

◆ 시계열 그래프 예시


- ✓ 존슨앤드존슨의 분기별 수익(1960년~1980년)



1. 시계열의 구성요소 이해

◆ 세 가지 구성요소

- ✓ 추세Trend
- ✓ 계절성Seasonality
- ✓ 잔차Residual
- ✓ 시계열 분해



1. 시계열의 구성요소 이해

◆ 시계열 분해 $\Rightarrow$ 세 가지 구성요소로 분리

- ✓ 추세Trend : 시계열의 장기적인 변화
- ✓ 계절성Seasonality : 계절적인 변동 (1년 4번의 분기 동안 주당 순이익이 낮게 시작 연말에 감소)
- ✓ 잔차Residual : 추세 및 계절성으로 설명할 수 없는 행태 (백색소음)

1. 시계열의 구성요소 이해

◆ 예측 Forecasting 프로세스

- ✓ 목적 설정
- ✓ 목적 달성하기 위해 무엇을 예측해야 하는지 결정
- ✓ 예측할 기간 설정
- ✓ 데이터 수집
- ✓ 예측 모델 개발
- ✓ 상용 환경에 배포
- ✓ 모니터링
- ✓ 새로운 데이터 수집

1. 시계열의 구성요소 이해

◆ 시계열 예측의 주요 특징

- ✓ 수치 예측을 한다는 점에서 회귀와 비슷하지만, 시간의 순서 관점에서 다름
 - 시계열 : 시간의 순서를 지켜야 함
 - 회귀 : 시간의 순서가 존재하지 않는 경우가 많음
- ✓ 시계열은 그 자체 이외에 다른 특징 활용하지 않고 시계열만 활용해서 예측

2. 베이스라인 모델 정의

◆ Baseline Model

- ✓ 간단한 통계 기법 활용 (산술평균), 예시
 - 1960년부터 1979년까지 평균 주당순이익 : \$4.31
 - 1980년 분기당 \$4.31 예측

2. 베이스라인 모델 정의

◆ 예측 성능 평가

- ✓ 평가지표 : 평균절대백분율오차(Mean Absolute Percentage Error, MAPE)
 - 해석하기 쉽고, 데이터의 규모에 영향을 받지 않음



$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{A_i - F_i}{A_i} \right| \times 100$$

- 용어
 - A_i : 실젯값
 - F_i : 예측값
 - n : 예측 횟수

2. 베이스라인 모델 정의

◆ 두 모델 비교


- ✓ 예측값이 너무 멀지 않은 과거의 값과 연관이 있을 가능성이 높음 확인 가능 (자기상관)



2. 베이스라인 모델 정의

◆ 두 모델 비교

- ✓ 계절적 요인 적용 시, 가장 좋은 성능을 보여줌



3. 확률보행 프로세스

◆ 확률보행 시계열 모델 프로세스

- ✓ 정상성Stationary 확인
- ✓ 만약 비정상성이라면
 - 차분Differencing을 통해 정상성으로 변환
- ✓ 자기상관함수ADF: Auto-Correlation Function를 도식화하여 확률보행 시계열 모델로 근사화
Approximation
- ✓ 시계열 예측

3. 확률보행 프로세스

◆ 확률보행 수식

$$y_t = C + y_{t-1} + \varepsilon_t$$

✓ 용어 정리

- y_t : 현재값
- y_{t-1} : 이전 시간 단계의 값
- C : 상수
- ε_t : 난수

3. 확률보행 프로세스

◆ 확률보행 수식 시뮬레이션

$$y_t = C + y_{t-1} + \varepsilon_t$$

- ✓ 만약, 상수 C 가 0이면, 초깃값 y_t 을 0으로 지정하면 아래와 같은 수식으로 다시 정리가 될 수 있음


$$y_t = \sum_{t=1}^T \varepsilon_t$$

- ✓ 수식 해석
 - 임의의 시점 t 에서 시뮬레이션된 시계열의 값이 일련의 난수들의 누적 합임을 표현

3. 확률보행 프로세스

◆ 확률보행 수식 시뮬레이션


- ✓ 1,000개의 샘플
- ✓ 백색소음(난수)의 누적합계 계산



3. 확률보행 프로세스

◆ 확률보행 식별

- ✓ 확률보행의 정의 : 첫 번째 차분이 정상적이고 상관관계는 없는 시계열로 정의






3. 확률보행 프로세스

◆ 정상성 테스트

- ✓ ADF : Augmented Dickey-Fuller
- ✓ 시계열 변환 적용 후, 정상성 테스트 수행하여 다른 변환 더 적용해야 하는지 확인 (ADF)
- ✓ 시계열 가설 검정
 - 귀무가설 : 단위근 unit root 이 존재 (시계열이 비정상적)
 - 대립가설 : 단위근이 없으므로 시계열이 정상적이라는 가설

3. 확률보행 프로세스

◆ 정상성 테스트



3. 확률보행 프로세스


◆ 자기상관관계 Autocorrelation 테스트

- ✓ 상관관계 : 두 변수 사이의 선형 관계 측정
- ✓ 자기상관관계 : 시계열의 선행값과 후행값 사이의 선형 관계 측정
- ✓ 지연^{lag}이 증가함에 따라 두 값 사이의 상관관계가 어떻게 변하는지 보여줌
 - 두 값 사이의 시간 단계
 - lag 1 : y_t, y_{t-1} 사이의 관계
 - lag 2 : y_t, y_{t-2} 사이의 관계
 - lag 0 : 자기상관계수는 언제나 1
- ✓ 추세가 존재 : lag 숫자가 커지면서 계수가 선형적으로 감소
- ✓ 계절성이 존재 : 주기적인 패턴 확인

3. 확률보행 프로세스

◆ 자기상관관계 Autocorrelation 테스트


- ✓ 비정상 시계열의 자기상관관계 시각화 예시
 - 지연이 증가함에 따라 서서히 감소
 - 시계열은 정상 시계열이 아님
 - 지연 20에서도 상관계수 존재
 - 해결방안 : 차분




3. 확률보행 프로세스

◆ 자기상관관계 Autocorrelation 테스트

- ✓ 정상 시계열의 자기상관관계 시각화 예시 (정상적인 확률보행 시각화)
 - 차분 진행 후, 시각화



추세 제거하여 분산 안정화 된 그래프




지연 0 이후에 유의한 상관계수 없음

3. 확률보행 프로세스

◆ 자기상관관계 Autocorrelation 테스트



- ✓ ACF 도식에서 유의한 상관계수 없음
- ✓ 5와 18은 유의하지 않기는 하지만, 우연한 상황으로 추정 가능



3. 확률보행 프로세스

◆ 확률보행 예측


✓ 추세 제거 및 ACF 테스트 통과 ⇒ 미래 예측 가능



3. 확률보행 프로세스

◆ 확률보행 식별

- ✓ 확률보행의 정의 : 첫 번째 차분이 정상적이고 상관관계는 없는 시계열로 정의



2. 통계적 모델을 활용한 시계열 예측


학습목표

- ▶ 이동평균과정 정의
- ▶ ACF를 사용하여 이동평균과정의 차수 식별
- ▶ 이동평균 모델을 사용하여 시계열 예측

1. 이동평균 모델링

◆ 확률보행 식별

- ✓ 확률보행의 정의 : 첫 번째 차분이 정상적이고 상관관계는 없는 시계열로 정의



1. 이동평균 모델링

◆ 이동평균과정 정의

- ✓ 이동평균MA: Moving Average Process은 현재값이 현재와 과거 오차에 선형적으로 비례
 - 오차가 백색소음과 마찬가지로 상호 독립적이며 정규분포한다고 가정
 - 오차항은 정규분포를 따름
- ✓ 이동평균 모델 = $MA(q)$, q 는 차수

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \cdots + \theta_q \varepsilon_{t-q}$$

- 용어 정리
 - y_t : 현재값
 - μ : 수열의 평균
 - ε_t : 현재 오차항
 - ε_{t-q} : 과거 오차항
 - θ_q : 현재값에 과거 오차가 미치는 영향의 크기

1. 이동평균 모델링

◆ 이동평균과정 정의

- ✓ 이동평균 모델의 차수 q 정의
 - q 가 클수록 더 많은 과거 오차 항이 현재값에 영향을 미침

- ✓ MA(1)


$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1}$$

- ✓ MA(2)

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}$$

1. 이동평균 모델링

◆ 이동평균과정 차수 식별




1. 이동평균 모델링


◆ 이동평균과정 차수 식별

✓ 지연 2까지 유의한 계수 확인 $\Rightarrow$ MA(2) 모델


XYZ 위젯 회사의 위젯 판매량 데이터



1차 차분한 데이터 시각화 $\Rightarrow$ 분산 대략 안정



자기상관관계 시각화



1. 이동평균 모델링

◆ 이동평균과정 예측하기

- ✓ 전체 데이터 500일, 훈련데이터와 테스트데이터 비율 9:1
- ✓ 이동평균 모델은 한 번에 50단계 앞 예측 할 수 없음
 - 이동평균 모델의 특수성
 - 과거 오차 항에 선형적으로 의존
 - 데이터 집합에서 관찰되지 않기 때문에 재귀적으로 추정
- ✓ $MA(q)$ 모델은 앞으로의 q 단계까지만 예측

1. 이동평균 모델링

◆ 이동평균과정 예측하기

✓ 롤링 예측 rolling forecast



- MA(2) 모델 가정
- 첫번째 반복 : 첫번째~449번째 시간 단계 훈련, 450번째, 451번째 시간 단계 예측
- 두번째 반복 : 첫번째~451번째 시간 단계 훈련, 452번째와 453번째 시간 단계 예측

구분	1	449	450	451	452	453	...	498	499
첫번째 반복	훈련데이터		예측데이터						
두번째 반복	훈련데이터				예측데이터				
...									
마지막								예측데이터	

1. 이동평균 모델링


◆ 기존 모형과 비교

- ✓ 기존 모델보다 예측 성능이 향상된 것 확인



2. 자기회귀과정 모델링




◆ 이동평균과정 차수 식별



2. 자기회귀과정 모델링

◆ 소매점 주간 평균 데이터, 차분, ACF 시각화

- ✓ 정상적인 시계열이 아님 $\Rightarrow$ 차분 $\Rightarrow$ ACF 시각화
- ✓ 서서히 감소하는 추세 $\Rightarrow$ 자기회귀과정임을 나타냄



2. 자기회귀과정 모델링

◆ 자기회귀과정 정의

- ✓ 예측값이 이전 값에만 선형적으로 의존한다고 가정, 변수가 자기 자신에게 회귀
- ✓ 자기회귀과정은 $AR(p)$ 모델 표현, p 는 차수 (현재값에 영향을 미치는 과거값들의 개수 결정)
- ✓ 수식

$$y_t = C + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t$$

▪ 용어 정리

- y_t : 현재값
- ε_t : 오차항
- C : 상수
- y_{t-p} : 과거값들의 선형 방정식
- ϕ_p : 과거값이 현재값에 미치는 영향의 크기

2. 자기회귀과정 모델링

◆ 자기회귀과정 정의

- ✓ AR(1)은 수식이 확률보행 모델과 유사

$$y_t = C + \phi_1 y_{t-1} + \varepsilon_t$$


- ✓ AR(2)

$$y_t = C + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$$

2. 자기회귀과정 모델링

◆ 정상적 자기회귀과정의 차수

- ✓ 이동평균과정의 차수 식별할 때 필요한 단계 확장



2. 자기회귀과정 모델링

◆ 편자기상관함수 PACF : Partial Autocorrelation Function

- ✓ 자기상관관계 : 시계열상 지연된 값들 간의 선형관계 측정
- ✓ 지연이 증가함에 따라 두 값 사이의 상관관계가 어떻게 변하는지 측정
- ✓ AR(2) 시나리오


$$y_t = 0.33y_{t-1} + 0.50y_{t-2}$$

- y_t 와 y_{t-2} 가 어떻게 관련되는지, 두 함수의 상관관계 측정
- y_{t-1} 도 y_t 에 영향을 미침
- y_{t-1} 영향을 제거해야 함 $\Rightarrow$ 편자기상관관계

2. 자기회귀과정 모델링

◆ 편자기상관함수 PACF : Partial Autocorrelation Function


- ✓ AR(2) : 지연 2 이후에 계수들이 유의하지 않음



2. 자기회귀과정 모델링

◆ 편자기상관함수 PACF : Partial Autocorrelation Function




- ✓ AR(3) : 지연 3 이후에 계수들이 유의하지 않음



2. 자기회귀과정 모델링

◆ 자기회귀과정 예측


- ✓ 소매점의 주간 평균 유동인구를 차분한 값에 대한 예측 결과



3. 복잡한 시계열 모델링

◆ 자기회귀이동평균과정

✓ 확률보행, 이동평균과정, 자기회귀과정 식별



3. 복잡한 시계열 모델링

◆ 자기회귀이동평균과정

✓ 수식 정리 : $ARMA(p, q)$

- p : 자기회귀 부분의 차수, 현재값에 영향을 미치는 과거값의 개수 결정
- q : 이동평균 부분의 차수, 과거 오차 항의 개수 결정

$$y_t = C + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \cdots + \theta_q \varepsilon_{t-q}$$

3. 복잡한 시계열 모델링

◆ 자기회귀이동평균과정


✓ 수식 정리 : $ARMA(p, q)$

- $ARMA(1, 1) := y_t = C + \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}$, AR(1), MA(1) 프로세스 결합
- $ARMA(2, 1) := y_t = C + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1}$, AR(2), MA(1) 프로세스 결합

3. 복잡한 시계열 모델링

◆ 자기회귀이동평균과정

✓ ARMA 프로세스 식별





3. 복잡한 시계열 모델링

◆ 자기회귀이동평균과정

- ✓ 정상적 ARMA 프로세스 식별, ARMA(1, 1)

$$y_t = 0.33y_{t-1} + 0.9\varepsilon_{t-1} + \varepsilon_t$$





3. 복잡한 시계열 모델링

◆ 자기회귀이동평균과정

- ✓ ACF그래프로는 MA 차수 판단 맞지 않음
- ✓ PACF그래프로는 AR 차수 판단 불가




모델링 절차 고안



3. 복잡한 시계열 모델링

◆ 자기회귀이동평균과정


✓ 일반적 모델링 절차 고안



3. 복잡한 시계열 모델링

◆ 자기회귀이동평균과정

✓ 일반적 모델링 절차 고안



3. 복잡한 시계열 모델링

◆ 자기회귀이동평균과정

✓ 아카이케 정보 기준

$$AIC = 2k, 2\ln(\hat{L})$$

▪ 용어 정리

- k : 모델의 매개변수 개수
- $\hat{L}$: 가능도 함수의 최댓값



✓ AIC 값이 낮을수록 더 좋은 모델

3. 복잡한 시계열 모델링

◆ 자기회귀이동평균과정

✓ 잔차분석 : Q-Q 도식 확인

- 모델의 잔차가 정규분포인가? 가설 검증하기 위한 시각적 도구
- 정규분포인 경우, 잔차가 백색소음과 유사하여 모델의 적합도가 좋다는 뜻



4. 비정상적 시계열 예측

◆ 자기회귀누적이동평균(Autoregressive Integrated Moving Average, ARIMA)

- ✓ 자기회귀과정 : $AR(p)$, 적분 $I(d)$, 이동평균과정 $MA(q)$ 의 조합
- ✓ ARMA와의 차이점
 - ARMA : 원본 수열 사용
 - ARIMA : 차분된 수열 사용

4. 비정상적 시계열 예측

◆ 자기회귀누적이동평균(Autoregressive Integrated Moving Average, ARIMA)

- ✓ 자기회귀과정 : $AR(p)$, 적분 $I(d)$, 이동평균과정 $MA(q)$ 의 조합
- ✓ 수식 활용

$$y'_t = C + \phi_1 y'_{t-1} + \phi_2 y'_{t-2} + \cdots + \phi_p y'_{t-p} + \theta_1 \varepsilon'_{t-1} + \theta_2 \varepsilon'_{t-2} + \cdots + \theta_q \varepsilon'_{t-p} + \varepsilon_t$$

▪ 용어 정리

- y'_t : 차분된 수열의 현재값
- C : 상수값
- $\phi_1 y'_{t-1}$: 차분된 수열의 과거값
- $\theta_q \varepsilon'_{t-p}$: 과거 오차항
- ε_t : 현재 오차항의 합


▪ 차수 정리

- p : 지연된 값의 개수 결정, q : 지연된 오차 항의 개수

4. 비정상적 시계열 예측

◆ 자기회귀누적이동평균(Autoregressive Integrated Moving Average, ARIMA)


✓ ARMA 모델링 절차



4. 비정상적 시계열 예측

◆ 자기회귀누적이동평균(Autoregressive Integrated Moving Average, ARIMA)



✓ ARMA 모델링 절차



4. 비정상적 시계열 예측

◆ 자기회귀누적이동평균(Autoregressive Integrated Moving Average, ARIMA)


- ✓ 예측 데이터셋 : 존슨앤드존슨의 분기별 주당 순이익과 예측 구간 구하기



4. 비정상적 시계열 예측

◆ 자기회귀누적이동평균(Autoregressive Integrated Moving Average, ARIMA)



- ✓ ARIMA(3, 2, 3) 모델 피팅 후, 잔차 진단 표시



4. 비정상적 시계열 예측

◆ 자기회귀누적이동평균(Autoregressive Integrated Moving Average, ARIMA)


✓ Baseline 모델과 비교



5. 계절성을 고려한 시계열 예측

◆ 계절적 자기회귀누적이동평균(Seasonal ARIMA, SARIMA)

- ✓ 시계열에 계절적 패턴 포함
- ✓ 항공사의 월별 총 항공 승객 수



5. 계절성을 고려한 시계열 예측

◆ 계절적 자기회귀누적이동평균(Seasonal ARIMA, SARIMA)

✓ 모델 살펴보기

$$SARIMA(p, d, q)(P, D, Q)_m$$

▪ 용어 정리

- m : 빈도를 나타냄, 빈도 : 주기당 관측 횟수로 정의

✓ 데이터에 따른 적절한 빈도 m

데이터 수집	빈도 m
연간	1
분기별	4
월간	12
주간	52

5. 계절성을 고려한 시계열 예측

◆ 계절적 자기회귀누적이동평균(Seasonal ARIMA, SARIMA)

- ✓ 일 단위 및 하위 시간 단계 데이터에 대한 적절한 빈도 m 예시

데이터 수집	빈도 m				
연간	분	시간	일	주	년
매일				7	365
시간별			24	168	8766
매분		60	1440	10080	525960
매초	60	3600	86400	604800	31557600

5. 계절성을 고려한 시계열 예측

◆ 계절적 자기회귀누적이동평균(Seasonal ARIMA, SARIMA)


- ✓ P, D, Q 의 의미 : ARIMA 모델에서 계절적으로 상응하는 값
 - P : 계절적 $AR(p)$ 의 차수
 - D : 계절적 적분 차수
 - Q : 계절적 $MA(q)$ 의 차수
- ✓ 만약, P, D, Q 가 모두 0이면 ARIMA 모델과 동일함

5. 계절성을 고려한 시계열 예측

◆ 계절적 자기회귀누적이동평균(Seasonal ARIMA, SARIMA)

✓ 수식 응용



- m 이 12인 경우의 데이터, 매년 7-8월에 연중 항공 승객 수가 많음



5. 계절성을 고려한 시계열 예측

◆ 계절적 자기회귀누적이동평균(Seasonal ARIMA, SARIMA)


- ✓ 계절별 패턴 식별 : 도식화, 시계열 분해 (추세, 계절, 잔차)



5. 계절성을 고려한 시계열 예측

◆ 계절적 자기회귀누적이동평균(Seasonal ARIMA, SARIMA)



- ✓ 계절별 패턴 식별 : 도식화, 시계열 분해 (추세, 계절, 잔차)
 - 계절적 구성요소 : 관측 데이터에서 최고점과 최저점 생성



5. 계절성을 고려한 시계열 예측

◆ 계절적 자기회귀누적이동평균(Seasonal ARIMA, SARIMA)


- ✓ 계절별 패턴 식별 : 도식화, 시계열 분해 (추세, 계절, 잔차)
 - 계절성이 없으면 구성요소가 0에서 평평한 수평선으로 표시
 - 시계열에서 계절성을 식별하는 통계적 테스트는 미 존재



5. 계절성을 고려한 시계열 예측

◆ 계절적 자기회귀누적이동평균(Seasonal ARIMA, SARIMA)


✓ ARIMA 시계열 예측 프로세스



5. 계절성을 고려한 시계열 예측

◆ 계절적 자기회귀누적이동평균(Seasonal ARIMA, SARIMA)


✓ SARIMA 시계열 예측 프로세스



5. 계절성을 고려한 시계열 예측

◆ 계절적 자기회귀누적이동평균(Seasonal ARIMA, SARIMA)


- ✓ ARIMA(11, 2, 3) 모델의 잔차 진단
 - 잔차는 백색소음에 가까우며, 오차가 무작위임



5. 계절성을 고려한 시계열 예측

◆ 계절적 자기회귀누적이동평균(Seasonal ARIMA, SARIMA)

- ✓ SARIMA(2, 1, 1)(1, 1, 2)₁₂ 모델의 잔차 진단
 - 잔차는 백색소음에 가까우며, 오차가 무작위임





5. 계절성을 고려한 시계열 예측

◆ 계절적 자기회귀누적이동평균(Seasonal ARIMA, SARIMA)

✓ 예측 테스트 및 모델 비교

- 계절성을 고려한 모델의 성능이 기존 ARIMA 모델보다 더 좋음



6. 모델에 외생 변수 추가

◆ SARIMAX 모델

- ✓ 외생변수 Exogenous Variable : 예측 변수 또는 입력 변수 설명
- ✓ 내생변수 Endogenous Variable : 예측하고자 하는 대상 변수 정의
- ✓ 예시 : GDP

$$GDP = C + G + I + NX$$

- 용어 정리

- C : 소비
- G : 정부 지출
- I : 투자
- NX : 순수출

- ✓ 각 요소는 외생 변수의 영향을 받음
 - 예시 : 소비는 실업률의 영향

6. 모델에 외생 변수 추가

◆ SARIMAX 모델

✓ 수식

$$y_t = SARIMA(p, d, q)(P, D, Q)_m + \sum_{i=1}^n \beta_i X_t^i$$

- 기존 SARIMA 모델에 외생 변수를 추가
- 계절적 패턴이 없는 경우 ARIMAX 모델
- 외생변수가 없으면 SARIMA 모델
- 계절성이나 외생변수가 없으면 ARIMA 모델

6. 모델에 외생 변수 추가

◆ SARIMAX 모델


✓ 거시경제 데이터 집합

변수	설명	변수	설명
realgdp	실질 GDP(목표 변수 또는 내생 변수)	pop	분기 말 총인구
realcons	실질 개인 소비 지출	infl	인플레이션율
realinv	실질 국내 총 민간 투자	realint	실질 이자율
realgovt	실질 연방 소비 지출 및 투자		
realdpi	실질 민간 가처분 소득		
cpi	분기 말 소비자물가지수		
M1	M1 명목 통화량		
tbilrate	3개월 만기 국채의 분기별 월평균 금리		
unemp	실업률		

6. 모델에 외생 변수 추가

◆ SARIMAX 모델

✓ 거시경제 데이터 집합 시각화



6. 모델에 외생 변수 추가

◆ SARIMAX 모델

- ✓ p-value 값 보다 중요한 것, AIC
 - 통상적으로 p값을 통해 중요 변수 선택하는데 활용
 - 회귀분석에서 p값은 계수와 0과 유의하게 다른지를 테스트 함
 - AIC가 가장 낮은 모델을 선택하여 이 단계를 수행해야 함W
 - 참고 : [Statistical Tests for variable selection](#)

6. 모델에 외생 변수 추가

◆ SARIMAX 모델


✓ 사용 시 유의사항

- $SARIMA(p, d, q)(P, D, Q)_m$ 모델과 외생 변수의 선형 조합 사용하여 미래의 한 시간 단계 예측 가능
- 미래의 두 시간 단계를 예측하기 위해서는 외생 변수도 예측
- 추천 : 미래의 하나의 시간 단계만 예측하고 외생 변수 관측 후, 미래의 다른 시간 단계 예측

6. 모델에 외생 변수 추가

◆ SARIMAX 모델


✓ SARIMAX 시계열 예측 프로세스



6. 모델에 외생 변수 추가

◆ SARIMAX 모델


✓ SARIMAX 시계열 예측 프로세스



6. 모델에 외생 변수 추가

◆ SARIMAX 모델

- ✓ SARIMAX 시계열 예측 프로세스



7. 다중 시계열 예측하기

◆ VAR Vector Autoregression 모델

- ✓ SARIMAX 모델에서는 관계가 단방향 (외생 변수 → 시계열 대상 데이터)
- ✓ VAR 모델 : 두 시계열이 양방향 관계를 가짐
- ✓ 양방향 관계의 예시 (예시 변수, 실질 소비와 실질 가처분 소득)
 - 가설1 : 가처분 소득이 많을수록 소비가 많다.
 - 가설2 : 소비가 많다는 것은 더 많은 가처분 소득이 있다.

7. 다중 시계열 예측하기

◆ VAR Vector Autoregression 모델

- ✓ VAR 모델은 여러 시계열을 예측할 수 있도록 $AR(p)$ 모델 일반화
- ✓ VAR(1) 모델 수식 (행렬곱셈)


$$\begin{bmatrix} y_{1,t} \\ y_{2,t} \end{bmatrix} = \begin{bmatrix} C_1 \\ C_2 \end{bmatrix} + \begin{bmatrix} \phi_{1,1} & \phi_{1,2} \\ \phi_{2,1} & \phi_{2,2} \end{bmatrix} \begin{bmatrix} y_{1,t-1} \\ y_{2,t-1} \end{bmatrix} + \begin{bmatrix} \epsilon_{1,t} \\ \epsilon_{2,t} \end{bmatrix}$$

- ✓ VAR 모델도 시계열이 정상적이어야 함

7. 다중 시계열 예측하기

◆ VAR 모델

✓ VAR 시계열 예측 프로세스



7. 다중 시계열 예측하기


◆ VAR 모델

- ✓ VAR 시계열 예측 프로세스
- ✓ 그레인저 인과관계 테스트 실행 시, 실패하면 $\text{VAR}(p)$ 모델 유효하지 않음, 절차 중지
 - 귀무가설 : 한 변수가 다른 변수를 예측하는데 도움이 되지 않는다.
 - 대립가설 : 한 변수가 다른 변수를 예측하는데 도움이 된다.

7. 다중 시계열 예측하기

◆ VAR 모델


✓ realdpi(실질 가처분 소득) 잔차 분석 vs realcons(실질 소비) 잔차 분석 비교



7. 다중 시계열 예측하기

◆ VAR 모델

- ✓ realdpi(실질 가처분 소득), realcons(실질 소비)에 대한 예측 결과의 MAPE





THANK YOU.

